

LAPORAN PRAKTIKUM DATA WAREHOUSE

9. DATA INVENTORY TABLE (SKEMA SOURCE LAYER)

Tabel inventory berikut menyajikan ringkasan struktur meta-data dari lima file sumber mentah yang telah berhasil dimasukkan ke dalam skema `src` di database PostgreSQL:

TABEL	JUMLAH BARIS	JUMLAH KOLOM	NATURAL KEY CANDIDATE	PERAN BISNIS
<code>program_studi</code>	6	5	<code>kode_prodi</code>	Master/Reference Program Studi
<code>semester</code>	8	6	<code>semester_id</code>	Reference Semester
<code>mahasiswa</code>	1.965	11	<code>nim</code>	Master Mahasiswa
<code>dosen</code>	96	7	<code>nidn</code>	Master Dosen
<code>mata_kuliah</code>	208	7	<code>kode_mk</code>	Master Mata Kuliah

11. PROBLEM CHALLENGE (PERTANYAAN & JAWABAN 1 - 4)

1. Jumlah Baris pada Masing-Masing Tabel Sumber

Jawaban: Berdasarkan query inventory data, jumlah baris untuk kelima tabel adalah: `program_studi` = 6 baris, `semester` = 8 baris, `mahasiswa` = 1.965 baris, `dosen` = 96 baris, dan `mata_kuliah` = 208 baris.

2. Jumlah NIM Unik pada `mahasiswa.csv` vs Total Baris

Jawaban & Alasan: Jumlah NIM unik (`DISTINCT nim`) **tidak sama** dengan total baris data (1.965 baris). Hal ini menunjukkan bahwa dataset mentah `mahasiswa.csv` mengandung duplikasi record untuk NIM yang sama (multiple entries).

```
SELECT COUNT(*) AS total_baris, COUNT(DISTINCT nim) AS distinct_nim FROM src.mahasiswa;
```

3. Jumlah Baris Excess Duplicate (NIM sebagai Natural Key)

Jawaban: Jumlah *excess duplicate rows* dihitung dari selisih `COUNT(*) - COUNT(DISTINCT nim)`. Baris duplikat ini merupakan baris redundan yang wajib dieliminasi pada tahap cleansing sebelum dimasukkan ke Dimension Table agar aturan keunikan Natural Key terpenuhi.

```
SELECT COUNT(*) - COUNT(DISTINCT nim) AS excess_duplicate_rows FROM src.mahasiswa;
```

4. Rentang Angkatan pada Base Load

Jawaban: Rentang angkatan ditentukan dengan mencari nilai minimum dan maksimum dari kolom `angkatan` pada tabel `mahasiswa`. Hasil query menunjukkan rentang angkatan mahasiswa yang tercakup dalam pemuatan awal (*base load*).

```
SELECT MIN(angkatan) AS angkatan_tertua, MAX(angkatan) AS angkatan_termuda
```

11. PROBLEM CHALLENGE (PERTANYAAN & JAWABAN 5 - 9)

5. Mahasiswa dengan Kota Asal Kosong (kota_asal_raw)

Jawaban: Jumlah mahasiswa dengan kota asal kosong dihitung menggunakan fungsi `COALESCE` dan `TRIM` untuk mengantisipasi nilai `NULL`, string kosong (`' '`), maupun spasi liar. Rekord ini tergolong sebagai *missing data* yang memerlukan penanganan khusus (misal diisi nilai default `'UNKNOWN'`).

```
SELECT COUNT(*) AS missing_kota FROM src.mahasiswa WHERE TRIM(COALESCE(kota_asal_raw, '')) = '';
```

6. Banyaknya Label prodi_raw vs Program Studi Canonical

Jawaban: Jumlah label unik `prodi_raw` pada tabel mahasiswa jauh lebih banyak dibandingkan 6 baris canonical pada tabel `src.program_studi`. Hal ini terjadi karena adanya variasi penulisan teks mentah (misal: "Informatika", "INFORMATIKA", "Teknik Informatika", atau variasi spasi).

```
SELECT (SELECT COUNT(DISTINCT prodi_raw) FROM src.mahasiswa) AS label_prodi_raw, (SELECT COUNT(*) FROM src.program_studi) AS prodi_canonical;
```

7. Minimal Tiga Pola Anomali Data Lainnya

- Inkonsistensi Format Tanggal:** Kolom `tanggal_lahir_raw` disimpan sebagai `TEXT` dengan gabungan format (`YYYY-MM-DD`, `DD/MM/YYYY`, dll) sehingga tidak bisa langsung diurutkan.
- Variasi Penulisan Jenis Kelamin:** Kolom `jk_raw` memuat berbagai variasi sinonim seperti `'L'`, `'P'`, `'Laki-Laki'`, `'Perempuan'`, `'M'`, `'F'`.
- Spasi Liar & Letter Case:** Nama entitas memuat **leading/trailing spaces** serta campuran huruf kapital/kecil yang berpotensi memutus integritas Foreign Key.

8. Pengelompokan File Dataset & Alasan Bisnis

Jawaban: Seluruh lima file (`program_studi`, `semester`, `mahasiswa`, `dosen`, `mata_kuliah`) tergolong sebagai **Master / Reference Data**. Alasan: Kelima dataset ini mendefinisikan entitas utama dan domain referensi yang bersifat statis/jarang berubah, serta tidak memuat peristiwa transaksi bisnis berulang yang mengandung ukuran kuantitatif (**measures**).

9. Pertanyaan Analitik Lanjutan & Dataset Tambahan

NO	PERTANYAAN ANALITIK LANJUTAN	DATASET TAMBAHAN YANG DIBUTUHKAN
1	Berapa Indeks Prestasi Semester (IPS) dan IPK mahasiswa per semester?	Fact KHS / Nilai: (<code>nim</code> , <code>kode_mk</code> , <code>semester_id</code> , <code>nilai_angka</code> , <code>sks</code>)
2	Berapa tingkat kelulusan tepat waktu (*Graduation Rate*) per prodi?	Fact Kelulusan / Yudisium: (<code>nim</code> , <code>tanggal_lulus</code> , <code>ipk_akhir</code> , <code>predikat</code>)
3	Berapa persentase kehadiran mahasiswa pada setiap mata kuliah?	Fact Presensi Perkuliahan: (<code>jadwal_id</code> , <code>nim</code> , <code>status_hadir</code> , <code>tanggal</code>)
4	Berapa total beban SKS mengajar dosen (*Rasio Dosen-Mahasiswa*)?	Fact Pengampuan MK / Jadwal: (<code>nidn</code> , <code>kode_mk</code> , <code>kelas_id</code> , <code>semester_id</code>)
5	Berapa total penerimaan UKT dan tingkat tunggakan per semester?	Fact Keuangan / Pembayaran: (<code>nim</code> , <code>semester_id</code> , <code>nominal_bayar</code> , <code>status_lunas</code>)

ELEMENT CT	PERTANYAAN REFLEKSI	JAWABAN MAHASISWA
Problem Identification	Masalah apa yang harus diselesaikan sebelum Data Warehouse dibangun?	Memastikan keutuhan data data integrity , mengidentifikasi duplikasi baris, mengatasi missing values , menyelaraskan variasi format data mentah unstandardized data , serta memetakan keterhubungan antar-tabel mentah sebelum proses ETL ke Staging/Dimension Table.
Decomposition	Bagaimana Anda memecah sumber data menjadi komponen yang lebih kecil?	Memecah analisis menjadi 3 tahapan utama: (1) Data Inventory untuk memeriksa struktur/ukuran tabel, (2) Eksplorasi Key & Granularitas untuk memeriksa duplikasi natural key, dan (3) Profiling Kualitas Data per kolom untuk mendeteksi anomali teks, tanggal, dan nilai kategorikal.
Pattern Recognition	Pola atau ketidakkonsistenan apa yang terlihat?	Terlihat pola inkonsistensi penulisan nama prodi, variasi format jenis kelamin (L / P vs Laki-Laki / Perempuan), variasi tipe string pada tanggal, serta adanya duplikasi baris pada entitas mahasiswa.
Abstraction	Informasi mana yang cukup penting untuk inventory awal?	Mengambil informasi penting yaitu: nama tabel, jumlah baris row count , jumlah kolom column count , kandidat Natural Key, serta peran bisnis masing-masing tabel sebagai acuan awal pemodelan data.
Evaluation	Bagaimana Anda membuktikan bahwa proses import berhasil?	Membandingkan statistik row count dan column count di database PostgreSQL (skema src) dengan metadata file sumber CSV asli, serta memastikan tidak ada kegagalan tipe data (*type casting failure saat penampungan awal.

13. PARAGRAF REFLEKSI (SOURCE LAYER DATA QUALITY)

Mengapa Source Layer Tidak Boleh Langsung Dianggap Benar dan Bersih?

Source layer (seperti skema **src**) dirancang khusus sebagai area penampung sementara (**landing zone**) yang menampung data mentah dari sistem OLTP atau file eksternal secara *as-is* (apa adanya) tanpa mengubah struktur maupun nilainya. Oleh karena itu, data pada *source layer* tidak boleh langsung dianggap benar dan bersih karena masih mengandung berbagai bentuk *data noise*, seperti duplikasi data, kesalahan format tanggal, spasi liar, inkonsistensi penulisan nama entitas, serta nilai yang hilang (**missing values**). Menggunakan data mentah secara langsung untuk analisis atau pemodelan Data Warehouse akan mengakibatkan laporan analitik yang tidak akurat, kekacauan hubungan antar-dimensi (**referential integrity breach**), serta hilangnya kepercayaan pemangku kepentingan terhadap informasi yang dihasilkan.